

# Distance

## Critère discret

### Problème

Soit un ensemble d'étudiants, ayant à choisir parmi une liste les activités qui les attire.  
On souhaite trouver la distance entre chaque étudiants.

### Formulation mathématique

Soit un vecteurs  $V = [v_0, \dots, v_n]$ .  
On a  $\forall i \in [0, n] : v_i \in \{0, 1\}$  tq  $v_i = 0$  si l'activité n'est pas selectionné et  $v_i = 1$  sinon.  
On peut alors représenter 2 étudiants par deux vecteurs  $V, W$ .  
Il nous faut alors trouver une distance entre ces deux vecteurs.

### Simplification du problème

**On suppose chaque critères indépendant.** On peut ainsi traiter chaque critères (ie chaque couple  $v_i, w_i$ ) indépendamment.

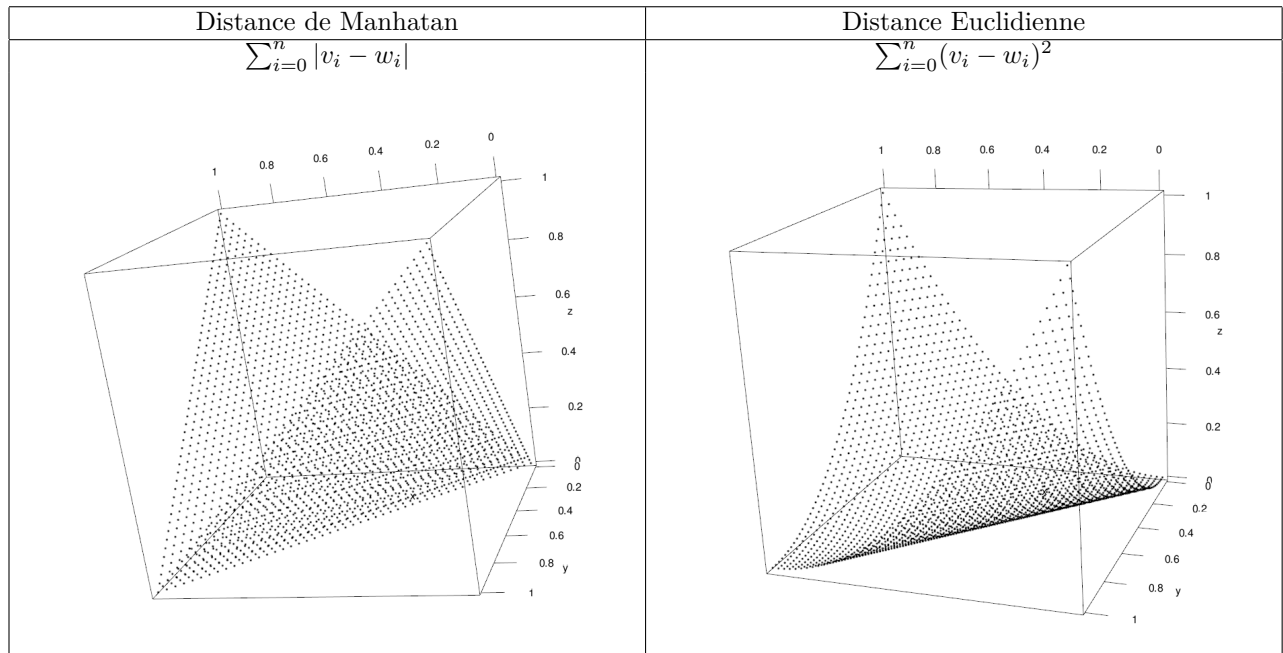
Il suffit alors de trouver une fonction  $D : \mathbb{R}^2 \rightarrow \mathbb{R}$  qui nous donne la distance entre  $v_i$  et  $w_i$  puis de sommer  $\forall i \in [0, n]$ .

Dans la suite on notera  $\forall (V = [v_0, \dots, v_n], W = [w_0, \dots, w_n]) \in (\mathbb{R}^n)^2 :$

$$D(V, W) = \sum_{i=0}^n D(v_i, w_i)$$

### Solution classique

Une implémentation classique de ce problème serait de prendre la distance de Manhatan ou la distance euclidienne.



Ces deux distances seront dans notre cas les même puisque l'on travaille dans l'ensemble  $\{\{0, 0\}, \{0, 1\}, \{1, 0\}, \{1, 1\}\}$ . Prenons donc la distance de Marshal (notée  $D$  pour la suite).

Soit 3 étudiants ayant fait les choix représentés par les vecteurs suivants:

- $E_1 = [1, 0, 0]$
- $E_2 = [1, 1, 0]$
- $E_3 = [1, 1, 1]$

On rappelle que cela signifie que :

- l'étudiant  $E_1$  est intéressé par le critère 1.
- l'étudiant  $E_2$  est intéressé par le critère 1 et 2.
- l'étudiant  $E_3$  est intéressé par le critère 1, 2 et 3.

On s'intéresse alors a la distance entre les élèves  $E_1$  et  $E_2$  et la distance entre les élèves  $E_1$  et  $E_3$ .

On obtient:  $D(E_1, E_2) = 1$  et  $D(E_1, E_3) = 1$

On a alors  $D(E_1, E_2) < D(E_1, E_3)$  ce qui est logique puisque  $E_1$  et  $E_2$  ont 2 critères en commun alors que  $E_1$  et  $E_3$  en ont 1 seul.

Cette approche est donc raisonnable, mais pas idéale. Nous allons expliquer pourquoi dans le prochain paragraphe.

## Problèmes posés par la solution classique

Bien qu'efficasse, les distances précédaments proposées ne sont pas idéales.

Reprenons notre exemple avec:

- $E_1 = [1, 0, 0]$
- $E_2 = [1, 1, 0]$
- $E_3 = [1, 1, 1]$

Et cette fois calculons la distance entre  $E_1$  et  $E_2$  et entre  $E_2$  et  $E_3$ .

On obtient:  $D(E_1, E_2) = 1$  et  $D(E_2, E_3) = 1$ . Donc  $D(E_1, E_2) = D(E_2, E_3)$ .

Cela peut sembler logique puisque chaque couple possède seulement un critère de différence.

Cependant si on pense au sens de ces critères, ce qui importe n'est pas tant que il en ai un maximum en commun que le fait qu'ils en ai un maximum **selectionné** en commun. C'est à dire un maximum de critère que les deux étudiants apprécient. Aussi, deux personnes s'apprécient pour les choses qu'elles partagent et pas pour l'infinité de non points commun qu'elles ont.

Ainsi il nous faut prendre en compte cette dissymétrie qui n'est pas représentée par les distances classiques *par définition*.

En effet on rappelle que pour  $D$  une distance on aura  $D(a, a) = 0$ .

Dans le paragraphe suivant nous tacherons donc de construire une distance entre deux personnes qui ne sera pas une distance suivant la définition classique mais qui répondra mieux à notre problème.

## Solution au problème de symétrie

Nous aurions pu limité le problème à notre exemple et contruire une fonction discrete (puisque nous travaillons dans l'ensemble  $\{\{0, 0\}, \{0, 1\}, \{1, 0\}, \{1, 1\}\}$ ).

Cependant dans un soucis de généralité nous proposons une fonction continue.

Les propriétés de cette fonction (notée  $D_P$ ) seront:

- Continuité
- Dérivabilité
- $D_P(1, 1) < D_P(0, 0) < D_P(1, 0)$  et  $D_P(1, 0) = D_P(0, 1)$


On définit un paramètre  $P$  qui sera la pénalité appliquée au point  $(0, 0)$ .

On définit alors:

$$D_P : \mathbb{R}^2 \longrightarrow \mathbb{R}$$

$$(x, y) \longmapsto P * \left[ 1 - 0.5(x + y) + \frac{1}{P-0.5} * (x - y)^2 \right]$$

Différents graphiques représentant  $D_P$  en faisant varier  $P$ .



Les propriétés de continuité et dérivabilité sont vérifiées de manière évidente.

De plus on a:

- $D_P(0, 0) = P$
- $D_P(1, 1) = 0$
- $D_P(1, 0) = D_P(0, 1) = 1$

Il suffit donc de prendre  $P \in ]0, 1[$  et on a bien  $D_P(1, 1) < D_P(0, 0) < D_P(1, 0)$  et  $D_P(1, 0) = D_P(0, 1)$ .

**Dans la suite on prendra donc  $P \in ]0, 1[$ .**

## Mise en oeuvre de la solution sur notre problème

Reprenons nos trois étudiants:

- $E_1 = [1, 0, 0]$
- $E_2 = [1, 1, 0]$
- $E_3 = [1, 1, 1]$

Appliquons maintenant la nouvelle fonction  $D_P$  au problème:

- $D_P(E_1, E_2) = 1 + P$
- $D_P(E_2, E_3) = 1$

Ainsi on a bien  $D_P(E_2, E_3) < D_P(E_1, E_2)$ .

La fonction  $D_P$  répond bien à notre problème.